Demostración OLS

Machine Learning

Tenemos la función

$$f = \sum_{i=1}^{n} (y_i - \hat{y}_i)^2 \tag{1}$$

donde n es el número de observaciones. f se denota RSS (suma de residuos al cuadrado). Como el modelo de regresión lineal simple es $\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i$, podemos sustituir en 1 y quedaría

$$\sum_{i=1}^{n} (y_i - (\hat{\beta}_0 + \hat{\beta}_1 x_i))^2$$

Sin embargo, aún no conocemos $\hat{\beta}_0$ y $\hat{\beta}_1$, ya que $\hat{}$ denota la **estimación** de β_0 y β_1. Luego, f es una función con parámetros β_0 y β_1, es decir, $f(\beta_0, \beta_1)$.

El mínimo de f se obtiene resolviendo el sistema de ecuaciones

$$\nabla f(\beta_0, \beta_1) = \begin{pmatrix} \frac{\partial f}{\partial \beta_0} \\ \\ \frac{\partial f}{\partial \beta_1} \end{pmatrix} = \begin{pmatrix} 0 \\ \\ 0 \end{pmatrix}$$

Desarrollando f tenemos

$$\sum y_i^2 - 2y_i(\beta_0 + \beta_1 x_i) + (\beta_0 + \beta_1 x_i)^2 = \sum y_i^2 - 2y_i\beta_0 - 2y_i\beta_1 x_i + \beta_0^2 + 2\beta_0\beta_1 x_i + \beta_1^2 x_i^2$$

Derivamos respecto de β_0 (β_1 es constante). Podemos derivar porque f es continua.

$$\frac{\partial f}{\partial \beta_0} = \sum(-2y_i + 2\beta_0 + 2\beta_1 x_i) = 2\sum(-y_i + \beta_0 + \beta_1 x_i) = 0$$

Luego,

$$\sum -y_i + \beta_0 + \beta_1 x_i = \sum -y_i + \sum \beta_0 + \sum \beta_1 x_i = -\sum y_i + n\beta_0 + \beta_1 \sum x_i = 0$$

Podemos sacar β_0 y β_1 como factor común, pues son constantes. Despejando β_0 tenemos

$$\hat{\beta}_0 = \frac{\sum y_i - \beta_1 \sum x_i}{n} = \bar{y} - \beta_1 \bar{x} \tag{2}$$

que es lo que queríamos. Le ponemos el gorrito $\hat{}$ porque ya hemos encontrado el mínimo para esa variable. En el último paso hemos utilizado que $\frac{\sum x_i}{n} = \bar{x}$, $\frac{\sum y_i}{n} = \bar{y}$ (la media).

Para el siguiente paso derivamos respecto de β_1 (β_0 es constante).

$$\frac{\partial f}{\partial \beta_1} = \sum -2y_i x_i + 2\beta_0 x_i + 2\beta_1 x_i^2 = 2\sum -y_i x_i + \beta_0 x_i + \beta_1 x_i^2 = 0$$

Luego,

$$\sum -y_i x_i + \beta_0 x_i + \beta_1 x_i^2 = \sum -y_i x_i + \sum \beta_0 x_i + \sum \beta_1 x_i^2 = -\sum y_i x_i + \beta_0 \sum x_i + \beta_1 \sum x_i^2 = 0$$

Sustituimos β_0 por 2

$$\begin{aligned} -\sum y_i x_i + (\bar{y} - \beta_1 \bar{x}) \sum x_i + \beta_1 \sum x_i^2 = -\sum y_i x_i + \bar{y} \sum x_i - \beta_1 \bar{x} \sum x_i + \beta_1 \sum x_i^2 = \\ = -\sum y_i x_i + \bar{y} \sum x_i + \beta_1 (\sum x_i^2 - \bar{x} \sum x_i) = 0 \end{aligned}$$

La media puede salir del sumatorio como factor común por ser constante. Despejando β_1 se tiene

$$\hat{\beta}_1 = \frac{\sum y_i x_i - \bar{y} \sum x_i}{\sum x_i^2 - \bar{x} \sum x_i} \overset{(*)}{=} \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2}$$

que es el punto buscado.

Demostramos la igualdad (*). (Puede saltarse esta parte)

Primero el numerador.

$$\begin{aligned} \sum (x_i - \bar{x})(y_i - \bar{y}) = \sum (x_i y_i - \bar{y} x_i - \bar{x} y_i + \bar{x}\bar{y}) = \sum x_i y_i - \sum \bar{y} x_i - \sum \bar{x} y_i + \sum \bar{x}\bar{y} = \\ = \sum x_i y_i - \bar{y} \sum x_i - \bar{x} \sum y_i + n\bar{x}\bar{y} = \sum x_i y_i - \bar{y} \sum x_i - \bar{x} \sum y_i + n\bar{x} \frac{\sum y_i}{n} = \\ = \sum x_i y_i - \bar{y} \sum x_i - \bar{x} \sum y_i + \bar{x} \sum y_i = \sum x_i y_i - \bar{y} \sum x_i \end{aligned}$$

Después el denominador.

$$\begin{aligned} \sum x_i^2 - \bar{x} \sum x_i = \sum x_i^2 - \sum \bar{x} x_i = \sum (x_i^2 - \bar{x} x_i) = \sum (x_i^2 - \bar{x} x_i - \bar{x} x_i + \bar{x} x_i) = \\ = \sum (x_i^2 - 2\bar{x} x_i + \bar{x} x_i) = \sum (x_i^2 - 2\bar{x} x_i) + \sum \bar{x} x_i = \\ = \sum (x_i^2 - 2\bar{x} x_i) + \bar{x} \sum x_i = \sum (x_i^2 - 2\bar{x} x_i) + \frac{\sum x_i}{n} \sum x_i = \sum (x_i^2 - 2\bar{x} x_i) + \frac{\sum x_i \sum x_i}{n} \cdot \frac{n}{n} = \\ = \sum (x_i^2 - 2\bar{x} x_i) + n\bar{x}^2 = \sum (x_i^2 - 2\bar{x} x_i + \bar{x}^2) = \sum (x_i - \bar{x})^2 \end{aligned}$$

□

Además, el punto es mínimo y no máximo porque f es suma de cuadrados (siempre términos positivos).